

Primeira Tarefa (Homework #1)

Disciplina CAP-394 – Ciência de Dados

Programa de Pós-Graduação em Computação Aplicada

Instituto Nacional de Pesquisas Espaciais

Objetivo: procurar em bases de dados abertas dados de meu interesse, verificar como acessar os dados, descrevê-los de forma resumida e ver que pergunta(s) podem ser respondidas com estes dados.

Tenho interesse pela história da ciência no Brasil, em particular sobre a evolução de temas de pesquisa. É uma informação com natureza complexa, mas podemos procurar por publicações a partir de temas e palavras-chaves com informação temporal. Devem existir inúmeras bases de dados sobre isto, mas as de maior visibilidade são a Plataforma Lattes (que restringe o acesso) e o portal de Dados Abertos da CAPES.

Escolhi procurar informações no portal da CAPES em <https://dadosabertos.capes.gov.br/>. Na categoria “Avaliação da Pós-Graduação Stricto Sensu” existem bases como “[2017 a 2020] Catálogo de Teses e Dissertações - Brasil” (outras semelhantes para outros anos). Verifiquei que posso obter informações de 1987 até 2024, separadas em blocos de anos.

Verificando no bloco “[1987 a 2012] Catálogo de Teses e Dissertações - Brasil” vi que existem arquivos Excel e CSV para cada ano base, além de informações sobre metadados. Para verificar os dados em si baixei a versão em Excel para o ano-base 1987. Verifiquei também o arquivo de metadados.

Na planilha investigada encontrei campos que identificam a instituição que gerou a produção, inclusive o Estado; nome do programa; área do conhecimento e avaliação; nome do discente autor da tese ou dissertação; título e palavras-chave; data da defesa; resumo textual. Verifiquei também que muitos campos estão vazios (possivelmente por causa da “idade” da informação) e que o campo **PalavrasChave** que seria crítico para esta pesquisa não tem formato unificado e várias falhas, mas pode ser possível analisar o texto do resumo filtrando por palavras específicas.

Quão fácil foi obter os dados?

Sim, o portal é aberto, os dados são organizados e bem identificados, não existem limitadores para acessar os dados, não é preciso registro prévio.

Estão bem documentados?

Sim, o próprio portal organiza os dados em categorias. Para cada conjunto de dados existem arquivos separados e descrições de metadados.

Os dados parecem organizados (*tidy*)?

Parcialmente. Os dados são organizados em planilhas, que são naturalmente organizadas em registros e campos; mas algumas células estão vazias e outras contêm informações mal formatadas (no caso, divisão entre as palavras-chaves em um dos campos). Veja a figura no final deste relatório para exemplos.

Os dados parecem completos?

Parcialmente. A falta de divisão e normalização das palavras-chave exigirá um processamento inicial mais cuidadoso. Veja a figura no final deste relatório para exemplos.

Precisaremos de mais dados desta ou de outras fontes?

Aparentemente não, podemos mapear a ocorrência de palavras-chaves por anos ou até meses se preciso. Outras fontes de dados complementares podem ser procuradas, mas para um estudo inicial esta seria suficiente.

Que perguntas posso responder com estes dados?

Algumas perguntas são:

1. Usando termos relacionados a uma área do conhecimento podemos mapear a produção de teses e dissertações nesta área?
2. Este mapeamento pode ser feito por instituição de ensino?
3. Que informações podemos obter correlacionando as instituições de ensino e áreas do conhecimento?

Existem riscos em usar estes dados para responder às perguntas?

Sim: a incompletude dos dados pode ser um problema para dados mais antigos, limitando a utilidade deles. A falta de unificação de palavras-chave pode complicar a criação de um mapeamento entre conceitos e as teses e dissertações.

PalavrasChave	Volume
CICLOTOMIA EXTENSOES DE CORPOS IRREDUTIBI	1
GRUPOS MATHIEU,SISTEMAS STEINER,CODIGOS DE GOLAY,GRUPOS FINITOS,TRANSITIVIDAD	1
MODELO LINEAR, RESIDUOS RECURSIVOS, METODOS GR	0
FORMAS ESPACIAIS, IMERSOES ISOMETRICAS, CURVATURA, ESPACO DE LORENTZ, DIRECAO AS	1
CODIGO CRIPTOGRAFICO, SEGURANCA DE DADOS, ALGORITMO, TEORIA DE COMPUTACA	1
PREVISAO DINAMICA SUPERPOPUL	1
ALGEBRAS DE CLIFFORD - IDEAIS MINIMAIS - SPINORES ALGEBRICOS - GRUPOS SPIN - EST	1
OPERADOR MAXIMAL/ESPACOS COM PESOS/ESPACO BMO/OPERADORES DE CALDERON ZYGMUND/OP	1
POLINOMIO INTERPOLATORIO RESOLUCAO ESPECTRAL MATRICIAL FUNCAO MAT	1
TEORIA DE DISTRIBUICOES PROBLEM A DE CAUCHY E DIRICHLET	1
TRACO DE ACAO, NUMERO DE LEFSCHETZ,TRANSFER GRAU, FUNCOES EQUIVARIANTE	1
EQUACOES DE REACAO-DIFUSAO - ELEMENTOS FINITOS E INFINITOS - EXPANSAO ASSINTOTIC	1
REGRESSAO LINEAR MULTIPLA - REGRESSAO LOGISTICA - PESO DE RECEM-NASCI DO - PERIN	1
ALGEBRAS,PONDERADA TRAIN ALGEBRA ALGEBRA GE	1
SUPERFICIE RIEMANNIANA,COMPRIMENTO DE GEODESICAS.	1
SUPERFICIES PSEUDO-ESFERICAS PROBLEMAS LINEARES TRANSFORMA	1
	0
SERIE DE FOURIER	1
POPULACOES FINITAS TENDENCIA LINEAR POPULACOES AUTOCORRELACIONADAS PREVISOR O	1
MODULOS DE NOS, MODULOS DE ENLACAMENTOS, ESPACOS DE REVESTIMENTO.	1
	1
EQUACOES DE EVOLUCAO,METODO DE GALERKIN,ESPACOS DE SOBOLEV,SOLUCOES FRACAS,EQUAC	1
POPULACOES FINITAS INFERENCIA BAYESIANA TOTAL POPULACIONAL PREVISORES DINAMIC	1
METODO VARIACIONAL RESSONANTE TEORIA DE	1
VARIEDADES INVARIANTES, DICOTOMIAS,SISTEMAS LINEARES PERTUBADOS	1
EFEITO DE Delineamento AmostrAl ESTATISTICA DE PEARSON - INDEPENDENCIA EM TAB	1
MODELO LINEAR,RESIDUOS RECURSIVOS,METODOS GRAFICOS.	1
	1
EQUACOES RETARDADAS, ESTABILIDADE, BIFURCACAO, MODELOS BIOLOGICOS	1
CURVAS ALGEBRICAS,AUTOMORFISMOS DECURBAS ALGEBRICAS,PONTOS FIXOS DE AUTOMORFISM	1
PROBLEMA DE CAUCHY, EQUACOES HIPERBOLICAS.	1
GENERICIDADE HIPERBOLICIDADE,ATRATORES SUPERFICIES,DIFEOMORFISMOS.	1
ZERO-MODAIS: CLASSIFICACAO.	1

Trecho da planilha obtida da CAPES com o campo PalavrasChave.